
Diseño de Fármacos y Biología Estructural

Modelado generativo de cadenas laterales de proteínas mediante difusión torsional en espacios no euclidianos

Noelia Fernández Espiñeira

Máster Universitario en Bioinformática y Bioestadística

Tutor: Brian Jiménez García - 16 de junio de 2026

Índice

01**Motivación y contexto***El problema de las cadenas laterales***02****Estado del arte***SCWRL4, DiffPack, AlphaFold3***03****Metodología y planificación***Arquitectura ChiGNN · Dataset · Entrenamiento***04****Resultados***Métricas, Benchmarking, Calibración***05****Conclusiones y trabajo futuro***Logros y líneas de mejora***06****Demo en vivo***Predicción con ChiGNN sobre una proteína nueva*

1. Motivación y contexto

El problema de las cadenas laterales

1. Motivación y contexto

✗ El problema

→ AlphaFold2 predice el backbone con alta fidelidad (TM-score > 0,9)...

→ ...pero la posición de los ángulos diedros χ_1 – χ_4 sigue siendo imprecisa: ~70–75% de recuperación en χ_1 .

→ Las cadenas laterales determinan los sitios activos enzimáticos, la unión de fármacos y los puentes de hidrógeno en la estructura terciaria.

→ Los métodos clásicos (SCWRL4, Rosetta) son deterministas: no capturan la distribución de conformaciones posibles.

✓ ChiGNN: la propuesta

Difusión torsional: sobre el espacio circular S^1 con distribución Von Mises

Red Neuronal de Grafos: (GNN) como función de denoising del proceso inverso

Calibración de incertidumbre: el modelo sabe cuándo no confiar en su predicción

Open Science: código, dataset y modelo publicados en GitHub y Zenodo

2. Estado del arte

Revisión SCWRL4, DiffPack, AlphaFold3


2. Estado del arte — Tabla comparativa de métodos

Método	Tipo	Rec. $\chi_1 \pm 40^\circ$	Incertidumbre	Coste cómputo
SCWRL4	Librería rotámeros	~83%	✗ No	Bajo
Rosetta FastRelax	Campo de fuerza	~85%	✗ No	Muy alto
AlphaFold2	Deep learning	~70–75%	✗ No	Alto
AlphaFold3	Difusión all-atom	>90%	Parcial	Muy alto
DiffPack	Difusión torsional	~87,5%	✓ Sí	Alto
ChiGNN (TFM)	Difusión torsional GNN	53,9%	✓ Calibrada (Von Mises)	Bajo (Colab T4)


2.1. ¿Por qué Von Mises? Estadística circular

¿Por qué Von Mises en lugar de Gaussiana?

**Distribución Gaussiana
(ignora periodicidad)**




**Distribución Von Mises
(respeto periodicidad circular)**



3. Metodología y planificación

Tres fases · 25 bloques · Google Colab T4

3. Pipeline del proyecto — Visión general



597

proteínas

156.407

residuos

80.404

parámetros

50

épocas

T4


GPU

3. Planificación

Teórica

Real

Actividad



3. Fase 1: Adquisición, curación y partición del dataset



3. Fase 1: Feature engineering: PDB → grafo PyTorch Geometric

INPUT — Features X (Backbone 3D)

Por cada residuo válido → Biopython extrae coords (x,y,z) de:

N Nitrógeno amídico → (x, y, z)

C_α Carbono alfa → (x, y, z)

C Carbono carbonílico → (x, y, z)

x [N×9] + aa_type [N] (entero 0–19)

3 átomos × 3 coords = 9 features por nodo
aa_type: 20 aminoácidos + 1 desconocido (0–20)

Filtros aplicados durante el parsing

✗ GLY y ALA excluidas —
sin χ_1 válido

✓ N, C_α, C, C_β
obligatorios —

✓ Orden secuencial
garantizado

✓ Post-filtro: residuos
sin χ_1 eliminados

TARGET — Targets Y (Ángulos χ_1 – χ_4)

calc_dihedral() — dependencia anidada
entre ángulos:

χ_1 N – C_α – C_β – C_γ *Todos (excl. GLY, ALA)*

χ_2 C_α – C_β – C_γ – C_δ *Mayoría*

χ_3 C_β – C_γ – C_δ – C_ε *GLU, GLN, MET, ARG, LYS*

χ_4 C_γ – C_δ – C_ε – C_ζ *ARG y LYS únicamente*

y [N×4] + y_mask [N×4] booleana

Si un átomo intermedio no existe → ángulos superiores = NaN.

NaN → 0,0 en y (ignorado por y_mask durante el entrenamiento)

Grafo PyTorch Geometric

Estructura torch_geometric.data.Data por proteína:

x [N×9] coordenadas backbone

aa_type [N] tipo de AA (0–19/20)

edge_index [2×2(N-1)] aristas bidireccionales

y [N×4] ángulos chi target

y_mask [N×4] máscara booleana

edge_index: N residuos → N–1 pares contiguos × 2 direcciones = **2(N–1) aristas**
→ Bidireccional: cada residuo recibe información de ambos vecinos en el grafo

Output: .pt (Drive) + .csv (respaldo tabular)

Todos los grafos serializados en dataset_torsional_diffusion.pt
+ dataset_sidechains_curated.csv (pdb_id · residue_name · N_x/y/z · CA_x/y/z · C_x/y/z · chi1–chi4)

3. Fase 2: Diseño del proceso forward: Difusión Torsional Von Mises

Decisiones de diseño del proceso forward

¿Por qué Von Mises y no Gaussiana?

Los ángulos diedros son variables circulares periódicas: χ y $\chi+360^\circ$ son el mismo ángulo. Una Gaussiana truncaría incorrectamente en $\pm 180^\circ$. Von Mises es la distribución nativa del círculo S^1 .

¿Por qué ruido aditivo?

Permite definir un proceso de Markov directo: cada paso t solo depende del paso anterior. Esto es el requisito matemático para poder invertir el proceso con una GNN (denoising).

¿Por qué schedule lineal de κ ?



El schedule lineal garantiza que el ruido se añade de forma gradual y controlada. $\kappa_{\max}=10,0$ ($t=0$): estructura casi intacta. $\kappa_{\min}=0,01$ ($t=T$): distribución prácticamente uniforme.

¿Por qué $T = 100$ pasos?

Equilibrio entre granularidad del proceso (más pasos = transición más suave) y coste computacional. $T=100$ es estándar en modelos de difusión para variables angulares.

Schedule κ y distribución Von Mises a lo largo del forward

Diseño del proceso forward: $\chi_t = \chi_0 + \varepsilon$, $\varepsilon \sim \text{Von Mises}(0, \kappa_t)$




Fórmula del proceso forward:

$$\chi_t = \chi_0 + \varepsilon, \quad \varepsilon \sim \text{Von Mises}(0, \kappa_t)$$

3. Fase 2: Arquitectura ChiGNN: diseño de la red de denoising

Diagrama de la arquitectura ChiGNN

Arquitectura ChiGNN: denoiser del proceso reverse



Elección de GCNConv

- Propagación de mensajes entre residuos vecinos en el grafo
- Cada residuo se conecta con sus vecinos inmediatos (residuo $i \rightarrow i \pm 1$)
- Versión 'lite': no equivariante (decisión de viabilidad en Colab T4)

BatchNorm + Conexión residual

- BatchNorm estabiliza activaciones con $\text{batch_size}=2$
- Conexión residual evita el problema del gradiente evanescente
- $h = h + \text{SiLU}(\text{BN}(\text{GCNConv}(h, E)))$ por cada capa

Encoding temporal t_{norm}

- $t/T \in [0, 1]$ informa al modelo en qué paso de difusión está
- Sin este encoding, el modelo no puede adaptar el denoising según el nivel de ruido
- Concatenado como feature adicional al input de cada nodo


sin/cos(χ_t) como encoding

- Los ángulos son periódicos: no se pasan directamente
- $\sin(\chi)$ y $\cos(\chi)$ son representaciones continuas y diferenciables
- [N×8]: 4 ángulos × 2 funciones trigonométricas

3. Fase 2: Diseño del entrenamiento y del proceso reverse

Diseño de la función de pérdida circular

Diseño de la función de pérdida: $L = 1 - \cos(\theta_{\text{pred}} - \theta_{\text{real}})$



Configuración del entrenamiento

Optimizador:	AdamW ($\text{lr}=10^{-3}$, $\text{weight decay}=10^{-4}$) → regularización adaptativa
Scheduler:	CosineAnnealingLR ($\text{eta}_{\text{min}}=10^{-5}$) → convergencia suave
y_mask:	Solo posiciones con valor real contribuyen al gradiente → evita aprender ceros ficticios
Grad clipping:	$\text{max_norm}=1,0$ → estabilidad con $\text{batch_size}=2$ (GNNs son sensibles a gradientes explosivos)

Diseño del proceso reverse: DDIM circular

¿Por qué DDIM y no DDPM estándar?

DDPM requiere T pasos de muestreo (100). DDIM es determinista y permite muestrear en solo $n_{\text{steps}}=20$ pasos con calidad comparable, reduciendo el tiempo de inferencia en $\sim 5\times$.

Algoritmo DDIM adaptado al espacio circular:

Inicio	$\chi_T \sim \text{Uniforme}[-\pi, +\pi]$ (ruido puro en $t=T$)
Por cada t: $T \rightarrow 1$	$\text{ChiGNN}(\chi_t, \text{aa}, \text{edge}, t/T) \rightarrow \text{predice } \hat{\chi}_0$
Si $t > 1$	$\chi_{\{t-1\}} \sim \text{Von Mises}(\hat{\chi}_0, \kappa_{\{t-1\}})$ (reinyección de ruido controlado)
Si $t = 1$	$\chi_{\text{pred}} = \hat{\chi}_0$ (predicción final sin ruido adicional)


Checkpointing y gestión de sesiones Colab

Early stopping:	Guardado del modelo solo cuando val_loss mejora → evita sobreajuste tardío
Drive persistence:	Artefactos (.pt) en Drive → reanudación sin re-entrenar
Control panel:	Flags booleanos (FORCE_) con lógica de cascada → reproducibilidad selectiva
Semillas fijas:	$\text{random.seed}(42)$, $\text{torch.manual_seed}(42)$

3. Fase 3: Diseño de las métricas de evaluación circular

Tres métricas de evaluación circular complementarias — ¿por qué cada una?

MAE Circular




MAE Circular

$$\text{mean}(\min(|\Delta\theta|, 360^\circ - |\Delta\theta|))$$

Por qué NO MSE: $\text{MSE}(170^\circ, -170^\circ) = 340^2$ (incorrecto: son el mismo rotámero). El MAE circular toma siempre el camino más corto sobre el círculo, respetando la periodicidad biológica de los ángulos diedros.

Umbral de recuperación de rotámeros




Recuperación de rotámeros

% predicciones con $\text{error_circ} < \text{umbral}$

Dos umbrales con significado biológico distinto. $\pm 40^\circ$: tolerancia estándar en docking ligando-proteína. $\pm 20^\circ$: criterio de alta precisión estructural. Un fármaco en desarrollo requiere típicamente $\pm 40^\circ$ para una predicción útil.

Bootstrap IC 95% (n=1.000)




Bootstrap IC 95% (n=1.000)

Remuestreo del test set con reemplazamiento

Por qué no solo la media: la media puntual no dice nada sobre la precisión estadística. El IC 95% permite comparar modelos con rigor: dos modelos son estadísticamente distintos solo si sus intervalos no se solapan.

3. Fase 3: Diseño de la calibración de confianza y el benchmarking

Diseño del análisis de calibración de confianza



Pasos del análisis de calibración diseñado

K = 10 muestras:	Ejecutar el proceso reverse K veces por residuo (no solo 1)
Varianza circular:	Calcular la varianza circular Von Mises de las K muestras por residuo
MAE real:	Comparar la predicción media con el ángulo experimental real
Spearman ρ:	Correlacionar varianza circular vs. MAE real → ¿predice el modelo su propio error?
Análisis deciles:	Dividir residuos en 10 grupos por varianza → ¿crece el error con la incertidumbre?

Diseño del benchmarking: selección de baselines

¿Por qué estos dos baselines y no otros?

Baseline aleatorio

Ángulos $\chi \sim \text{Uniforme}[-180^\circ, +180^\circ]$

Define la cota inferior absoluta: si el modelo no lo supera, no ha aprendido nada. Cero conocimiento sobre la biología de las proteínas.

Baseline modal

$\chi_1 = \arg \max P(\chi_1 | \text{tipo AA})$ — frecuencia en train set

Encarna el conocimiento estadístico sin aprendizaje contextual. Superar el modal demuestra que el modelo aprende dependencias entre residuos, no solo estadísticas marginales.

Referencia bibliográfica: SCWRL4

Limitación del diseño: No se puede instalar SCWRL4 en el entorno Google Colab. La comparación se realizará con los valores reportados en la literatura sobre un dataset distinto → comparación orientativa, no estadísticamente rigurosa. Se documenta esta limitación explícitamente en el análisis.

4. Resultados y discusión

Las tres fases del proyecto

4. Resultados Fase 1: Cimentación y preparación de los datos

597

proteínas curadas

156.407

residuos válidos (χ_1
definido)

311.620

aristas en el grafo

51,7%

posiciones χ con valor
real

477/60/60

train / val / test

Estadísticas del dataset curado


IDs consultados (RCSB REST API)	1.000
Con versión en PDB-REDO	598 (59,8 %)
Sin errores de procesamiento	597
Residuos totales (χ_1 definido)	156.407
Aristas totales en el grafo	311.620

Verificación del pipeline (batch 2 proteínas)

x	[356, 9] coords backbone 356 residuos
edge_index	[2, 708] = 2 × (356-2) aristas
y_mask	759 / 1.424 posiciones reales (53,3 %)

Distribución rotamérica χ_1 (rose plot) — Trimodalidad confirmada



Trimodalidad biológica confirmada: $g^- (\approx 300^\circ) > trans (\approx 180^\circ) > g^+ (\approx 60^\circ)$
· Fuente: elaboración propia a partir de datos PDB-REDO




✓ 0 errores en 597 proteínas · Pipeline completamente validado

4. Resultados Fase 2: Proceso forward y arquitectura ChiGNN

Verificación cualitativa del proceso forward (py3Dmol) — proteína de referencia

 $t=0$ | $\kappa=10,000$ | Residuos modificados: 135
(Mayor t → cadenas laterales más desordenadas)
  $t=25$ | $\kappa=7,502$ | Residuos modificados: 135
(Mayor t → cadenas laterales más desordenadas)
  $t=50$ | $\kappa=5,005$ | Residuos modificados: 135
(Mayor t → cadenas laterales más desordenadas)
  $t=100$ | $\kappa=0,010$ | Residuos modificados: 135
(Mayor t → cadenas laterales más desordenadas)



$t = 0$
 $\kappa = 10,0$
 Estructura real

$t = 25$
 $\kappa = 7,5$
 Desorden leve

$t = 50$
 $\kappa = 5,0$
 Desorden notable

$t = 100$
 $\kappa = 0,01$
 Ruido puro

Verificación cuantitativa: La distancia angular circular media (MAE circular) entre χ_0 y χ_t aumenta de forma **monótona** con t , de 0° ($t=0$) a $\sim 90^\circ$ ($t=100$) — valor esperado para distribución uniforme. Condición necesaria para el denoising.

Arquitectura ChiGNN implementada

80.404 parámetros entrenables

Embedding AA:	$21 \times 16 = 336$ params
input_proj:	$34 \rightarrow 128$ (+bias): 4.480
GCNConv $\times 4$:	~ 73.728 (conv + BatchNorm)
output_head:	$128 \rightarrow 64 \rightarrow 4$: ~ 8.320
Activación salida:	$\tanh \times \pi \rightarrow [-\pi, +\pi]$
Dimensión oculta:	128 (hidden_dim)
Capas GCN:	$4 \times \text{GCNConv} + \text{BN} + \text{Residual}$
Input por nodo:	34 features (9+16+8+1)


Proceso reverse sobre conjunto de test

60 proteínas del test set procesadas con $n_{\text{steps}}=20$ pasos DDIM. Predicciones serializadas en test_predictions.pt. Visualización 3D cualitativa sobre 2 proteínas confirma conformaciones estructuralmente coherentes.

4. Resultados Fase 2: Curva de aprendizaje y diagnóstico del entrenamiento

Curva de aprendizaje ChiGNN (50 épocas)

Curva de Aprendizaje — ChiGNN
Difusión Torsional para Recuperación de Cadenas Laterales



Diagnóstico del entrenamiento

Train loss (final)

0,1202

Val loss (mejor)

0,0885

Mejor época

42 / 50

Gap val-train

-0,0317

Diagnóstico

Sin over/underfitting

BatchNorm discrepancy

La val_loss es sistemáticamente menor que la train_loss por el uso de estadísticas móviles estabilizadas en inferencia [Ioffe & Szegedy, 2015]. El gap negativo (-0,0317) descarta el sobreajuste.

4. Resultados Fase 2: Validación visual del proceso reverse


2 proteínas del test set



Proteína: 1A2P

Residuos con χ_1 : 273 | MAE χ_1 : 58.82°


- Verde = cadenas laterales experimentales (original)
- Azul = cadenas laterales predichas (ChiGNN)



Proteína: 1BZ4

Residuos con χ_1 : 123 | MAE χ_1 : 57.25°

- Verde = cadenas laterales experimentales (original)
- Azul = cadenas laterales predichas (ChiGNN)



4. Resultados Fase 3: Métricas de evaluación y análisis por aminoácido

56,41°

MAE circular χ_1 [IC95%:
55,63–57,15°]

53,9%

Recuperación $\chi_1 \pm 40^\circ$

49,6%

Recuperación $\chi_1 \pm 20^\circ$

1.000

Bootstrap
remuestras

**[55,63°
57,15°]**

IC 95%

Métricas ChiGNN sobre el conjunto de test (60 proteínas)

Ángulo	N residuos	MAE circ. (°)	Rec. $\pm 20^\circ$	Rec. $\pm 40^\circ$
χ_1	19.627	56,41	49,6 %	53,9 %
χ_2	15.026	52,45	48,1 %	57,5 %
χ_3	5.302	52,72	40,0 %	53,4 %
χ_4 (ARG y LYS)	1.091	70,27	25,6 %	33,9 %


χ_4 exclusivo de ARG y LYS — MAE elevado esperado por alta flexibilidad y pocas muestras

Hallazgos por aminoácido

PRO	MAE $\approx 25^\circ$ — mejor resultado. Restricción cíclica $\rightarrow \chi_1$ casi determinista
SER	MAE $\approx 80^\circ$ — peor resultado. Hidroxilo terminal con baja barrera rotacional $\rightarrow$ distribución difusa
ILE/LEU /VAL	MAE 43–50°, Rec. >60% — rotámeros alifáticos bien definidos, por encima de la media global
ARG/LYS	MAE ≈ 54 –56°, Rec. $\approx 55\%$. Predecir χ_1 no garantiza el resto de la cadena

Rendimiento por tipo de aminoácido


Análisis de Rendimiento por Tipo de Aminoácido — ChiGNN



PRO: menor MAE · SER: mayor MAE · Línea verde = referencia SCWRL4 (~83%) · Todos los aminoácidos por debajo. Comparación no estadísticamente rigurosa (datasets distintos).

4. Resultados Fase 3: Distribuciones rotaméricas y calibración de confianza

Distribución rotamérica: Experimental (verde) vs. ChiGNN (azul) · χ_1 - χ_4



Fuente: elaboración propia · 36 bins de 10° · Normalizado por máximo · χ_4 exclusivo de ARG y LYS


χ_1 : Trimodalidad reproducida cualitativamente. Sobrerepresentación de g^- ($\approx 300^\circ$); subestimación de trans ($\approx 180^\circ$).

χ_2 : Mejor concordancia — pico principal en trans ($\approx 180^\circ$) bien reproducido. Coherente con el menor MAE (52,45°).

χ_3/χ_4 : Mayor dificultad. Predicción colapsa hacia trans; distribución experimental más difusa. MAE elevado esperado.

**Análisis de calibración de confianza (K=10
muestras) · $\rho = 0,299$ ($p < 0,001$)**

Análisis de Calibración de Confianza — ChiGNN



Fuente: elaboración propia

Interpretación de la calibración

$\rho = 0,299$ ($p < 0,001$)

Correlación moderada pero estadísticamente significativa entre varianza circular y MAE real.

D1 → D10 ($\sim 40^\circ \rightarrow \sim 73^\circ$)

Error medio crece con la incertidumbre: el modelo identifica sus peores predicciones.


Limitación

Alta dispersión: residuos con varianza alta y error bajo (sobreestimación de incertidumbre).

4. Resultados Fase 3: Benchmarking y tabla resumen consolidada

Benchmarking ChiGNN vs. Baselines (MAE circular ° y Recuperación ±40 %)

Benchmarking: ChiGNN vs. Baselines



Fuente: elaboración propia · Azul=ChiGNN · Rojo=Aleatorio · Naranja=Modal

Comparativa completa χ_1 – χ_4

Métrica	ChiGNN	Aleatorio	Modal	SCWRL4*
MAE χ_1 (°)	56,41	90,27	50,53	~24–28
Rec. χ_1 ±40%	53,9%	22,1%	58,6%	~83%
MAE χ_2 (°)	52,45	90,33	104,61	~30–35
Rec. χ_2 ±40%	57,5%	22,1%	18,4%	~75%
MAE χ_3 (°)	52,72	89,39	88,69	—
Rec. χ_3 ±40%	53,4%	22,6%	23,3%	—
MAE χ_4 (°)	70,27	90,95	118,14	—
Spearman ρ	0,299	—	—	—

* SCWRL4: valores de literatura, dataset distinto → comparación orientativa, no estadísticamente rigurosa

- ✓ ChiGNN supera al aleatorio en todos los ángulos (χ_1 : -37,5% MAE). El modelo aprendió geometría real.
- ~ Para χ_1 , el baseline modal lo supera ligeramente (50,53° vs 56,41°). El estado más frecuente es difícil de batir.
- ✓ Para χ_2 , χ_3 , χ_4 , ChiGNN supera ampliamente al modal. El modelo aprende dependencias contextuales que el modal no puede.
- △ Brecha con SCWRL4 (~83% χ_1): atribuida al dataset reducido (477 vs miles de proteínas) y arquitectura no equivariante.

Logro: ChiGNN supera al aleatorio en todos los ángulos y al modal en χ_2 – χ_4 . Demuestra que la difusión torsional con Von Mises es un marco técnicamente sólido con capacidad real de calibración ($\rho=0,299$, $p<0,001$).

5. Conclusiones y trabajo futuro

Ampliaciones y mejoras

5. Conclusiones

Conclusiones principales vinculadas a cada objetivo específico

O.E.1

Dataset curado y validado

Pipeline produce 597 proteínas y 156.407 residuos válidos de PDB-REDO (<2,0 Å). Partición 80/10/10 a nivel de proteína garantiza ausencia de data leakage. Rose plot confirma trimodalidad biológicamente esperada en χ_1 .

O.E.2-3

Proceso de difusión e implementación de ChiGNN

ChiGNN (80.404 parámetros) implementa correctamente el forward Von Mises y el reverse DDIM. Entrenamiento 50 épocas con AdamW + CosineAnnealingLR converge sin sobreajuste (gap val-train = -0,0317). Mejor checkpoint: época 42, val_loss = 0,0885.

O.E.4

Cuantificación de la tasa de recuperación

MAE circular $\chi_1 = 56,41^\circ$ [IC 95%: 55,63°; 57,15°]. Recuperación $\pm 40^\circ = 53,9\%$. Supera al baseline aleatorio en todos los ángulos y al modal en χ_2 , χ_3 y χ_4 . Brecha con SCWRL4 (~83%) cuantifica el margen de mejora futuro.

O.E.5

Validación rotamérica mediante rose plots

Rose plots comparativos confirman que ChiGNN reproduce cualitativamente la trimodalidad de χ_1 y la distribución trans-dominante de χ_2 . Tendencia a sobrerrepresentar el estado más frecuente (g^-) orienta mejoras hacia técnicas de temperatura de muestreo.

O.E.6

Calibración de confianza del modelo

$p = 0,299$ ($p < 0,001$) y patrón creciente D1→D10 (~40°→~73°) demuestran señal real de calibración. ChiGNN sabe cuándo no confiar en su predicción, ventaja cualitativa sobre SCWRL4 y métodos determinísticos.

GLOBAL

Conclusión general

ChiGNN constituye una prueba de concepto funcional de que la difusión torsional sobre Von Mises es un marco técnicamente sólido para el modelado de cadenas laterales, con capacidades de calibración que van más allá de las métricas de precisión clásicas. Todos los objetivos específicos cumplidos.

Pregunta de investigación

¿Es posible implementar un modelo de difusión torsional basado en GNN que aprenda la distribución de ángulos χ y supere a un predictor aleatorio?

✓ **SÍ, con matices importantes**

56,41°

MAE χ_1
[IC95: 55,63–57,15°]

53,9%

Rec. $\pm 40^\circ$
 χ_1 en test

 $p=0,299$

Calibración
Spearman

-37,5%

Reducción MAE
vs. aleatorio

5. Discusión: Limitaciones del estudio y contribuciones originales

Limitaciones identificadas (3 categorías)

Dataset reducido

- 477 proteínas de entrenamiento vs. ~7.000 de SCWRL4 y >100.000 de DiffPack.
- Filtro resolución <2,0 Å + PDB-REDO limita la cobertura taxonómica y estructural.
- Sesgo hacia proteínas globulares de tamaño medio sobrerrepresentadas en alta resolución.

Arquitectura no equivariante

- GCNConv estándar en lugar de EGNN o GVP: no garantiza equivariancia $E(3)$ ante rotaciones.
- Grafo lineal de aristas secuenciales ignora interacciones de largo alcance ($C\alpha-C\alpha < 8$ Å).
- Simplificación necesaria por restricciones de VRAM (15,6 GB) en Google Colab T4.

Proceso de evaluación

- Comparación con SCWRL4 es indirecta (valores de literatura, dataset distinto): no estadísticamente rigurosa.
- Proceso reverse usa $n_steps = 20$ de los $T = 100$ pasos, simplificación que puede reducir calidad.
- $K = 10$ muestras para calibración: estimadores de varianza con ruido relativamente alto.

Contribuciones originales del TFM

01

Marco de evaluación circular completo

MAE circular, varianza Von Mises y correlación de Spearman aplicadas sistemáticamente sobre los cuatro ángulos chi: framework robusto y reutilizable para futuros modelos de predicción de cadenas laterales.

02

Calibración de confianza como métrica primaria

Análisis de calibración mediante varianza circular de Von Mises sobre muestras del proceso reverse: contribución metodológica novedosa respecto a la literatura, que típicamente reporta solo MAE y tasas de recuperación sin análisis de incertidumbre.

03

Pipeline reproducible en entorno abierto

Notebook Google Colab con semillas fijas (random.seed(42), torch.manual_seed(42)), panel de control FORCE_*, artefactos en Zenodo (DOI: 10.5281/zenodo.20514250) y código en GitHub. Principios de Open Science.

5. Trabajo futuro — Líneas de desarrollo prioritarias

Escalado del dataset y arquitectura

1 Dataset completo

Incorporar la totalidad de PDB-REDO (>150.000 estructuras, resolución <2,0 Å). Un dataset 250× mayor permitiría reducir el MAE de χ_1 por debajo de 40°.

2 Capas equivariantes

Sustituir GCNConv por EGNN o GVP (equivarianza E(3)), garantizando que las predicciones son independientes de la orientación global de la proteína.

3 Grafos 3D

Ampliar edge_index con contactos $C\alpha-C\alpha < 8$ Å para capturar interacciones de largo alcance y el núcleo hidrofóbico de las proteínas.

Mejoras en el proceso de difusión

1 Schedule no lineal

Implementar schedules de tipo coseno o sigmoide para κ , que han demostrado mejor rendimiento que el lineal en modelos de difusión de imagen.

2 Más pasos reverse

Evaluar n_steps de 20 a 50/100 pasos en el proceso reverse para mejorar calidad de muestras a costa de mayor tiempo de inferencia.

3 Difusión autorregresiva

Seguir el esquema de DiffPack original: difusión secuencial $\chi_1 \rightarrow \chi_2 \rightarrow \chi_3 \rightarrow \chi_4$ en lugar de predecir los cuatro ángulos simultáneamente.

Evaluación y validación externa

1 Benchmark directo

Ejecutar ChiGNN y SCWRL4 sobre CASP15 para obtener comparación estadísticamente rigurosa sin dependencia de valores reportados con datasets distintos.

2 Validación en docking

Evaluar cadenas laterales predichas en cálculos de energía de unión ligando-proteína para cuantificar el impacto práctico sobre aplicaciones de diseño de fármacos.

3 Mejora calibración

Aumentar K de 10 a 100 muestras del proceso reverse. Explorar recalibración post-hoc (Platt scaling circular) para mejorar p por encima de 0,5.

Recomiendo:

① Dataset ×250

② Aristas 3D

③ EGNN / GVP

④ Benchmark
CASP15

⑤ K=100
muestras

⑥ Docking
válido

6. Demo en vivo

Observación real

Modelado generativo de cadenas laterales de proteínas mediante difusión torsional en espacios no euclidianos

[GitHub](#)

[Zenodo](#)

Noelia Fernández Espiñeira

Máster Universitario en Bioinformática y Bioestadística

Tutor: Brian Jiménez García - 16 de junio de 2026
